

דוח מסכם - Chest Health Classification

מגישים: רונן מיליכוב 322883224, שחר וילק 214149759

1. מבוא וסקירת הפרויקט

האתגר הרפואי ומטרת הפרויקט: העומס המוטל על מערכת הבריאות הוא כבד, במיוחד בתקופות של מגפות, ומביא לכך שרדיולוגים ורופאים קורסים תחת עומס האבחון של צילומי רנטגן. גורם הזמן הוא קריטי בתהליך זה, שכן אבחון איטי של מחלות כגון דלקת ריאות או קורונה עלול להוביל להחמרה רפואית קשה במצבו של המטופל. מטרת הפרויקט שלנו היא לפתח כלי עזר מבוסס בינה מלאכותית שיבצע סינון ראשוני ומהיר של צילומים אלו, יתריע על מקרים דחופים, ויקל על עבודת הצוות הרפואי. המערכת שפיתחנו מקבלת כקלט תמונות רנטגן דו-מימדיות דיגיטליות של בית החזה, ומסווגת אותן אוטומטית לאחת מארבע קטגוריות אבחון: קורונה, דלקת ריאות ויראלית, עכירות בריאה וריאה בריאה.

מאגר הנתונים (Dataset) המודל אומן על בסיס המאגר הפתוח "COVID-19 Radiography Database" שנלקח מאתר Kaggle. מאגר זה מכיל כמות גדולה ומספקת של למעלה מ-21,000 צילומי רנטגן מתויגים. המאגר המקורי כלל גם מטא-דאטה (Metadata) בקבצי Excel, אשר סיפק מידע על המקור הקליני של התמונות משיוכים למאגרים עולמיים. עם זאת, קיבלנו החלטה להתעלם לחלוטין מהנתונים הטבלאיים האלו. ההצדקה לכך הייתה לשמור על אופי הפרויקט כפרויקט טהור של ראייה ממוחשבת ועיבוד תמונה, כך שהמודל יאלץ לבסס את תחזיותיו אך ורק על המידע החזותי המופק מן התמונות עצמן. הנתונים חולקו ביחס של 80/20: 80% מהתמונות הוקצו לסט האימון (Training) כדי לאפשר למודל ללמוד ולכוון את המשקולות שלו, ו-20% הוקצו לסט הולידציה (Validation) על מנת לבחון את ביצועי המודל על נתונים חדשים שלא נראו מעולם.

עיבוד מקדים והכנת הנתונים לאימון (Data Preprocessing)

כדי להפוך את התמונות הגולמיות למידע שהרשת העצבית יכולה לעבד ביעילות וללמוד ממנו, ביצענו מספר פעולות טכניות בצינור הנתונים (Data Pipeline):

- **שינוי גודל (Resizing):** כיווצנו והבאנו את כל התמונות לאחידות בגודל של 224×224 פיקסלים. זהו הגודל הסטנדרטי המאפשר לרשתות קונבולוציה (CNN) לעבוד ביעילות.
- **נרמול ערכים (Normalization):** חילקנו את ערכי הפיקסלים בתמונות ב-255 כדי להמיר אותם מטווח הדרגות המקורי [0-255] לטווח שברים עדין של [0-1]. פעולה מתמטית זו מונעת קריסה של המודל בזמן הכפלות מרובות (תופעת ה-Exploding Gradients), ומאפשרת למודל לבצע צעדי למידה עדינים, יציבים ומהירים יותר.

- **טיפול בחוסר איזון (Class Imbalance):** מכיוון שסט הנתונים אינו מאוזן טבעית, הטמענו מנגנון המחשב את משקלי המחלקות (`class_weights`) ישירות מכמות הקבצים בתיקיות. חילקנו משקלים גבוהים יותר למחלקות המיעוט כדי לוודא שהמודל לא מפתח הטיה לטובת המחלקות הנפוצות ביותר (כמו דלקת ריאות ויראלית).
- **ייעול הזרמת נתונים לזיכרון:** כדי להתמודד עם קריסות של זיכרון ה-RAM במערכת Google Colab בעת עיבוד אלפי התמונות, הסרנו פונקציות אגירה כבדות (Caching) והשתמשנו בפונקציית `prefetch`. גישה זו מבטיחה שה-CPU מכין את אצוות התמונות הבאות במקביל לכך שכרטיס המסך (T4 GPU) מאמן את המודל על האצווה הנוכחית, מה שמבטיח אימון רציף ומהיר ללא חריגה ממגבלות החומרה.

2. עבודה קשורה (Related Work)

תחום האבחון הרפואי באמצעות למידה עמוקה וראייה ממוחשבת זכה לתשומת לב מחקרית עצומה בשנים האחרונות, ובפרט מאז פרוץ מגפת הקורונה (COVID-19). מחקרים רבים בחנו את היעילות של רשתות נוירונים קונבולוציוניות (CNN) לסיווג אוטומטי של מחלות ריאה מצילומי רנטגן (CXR). להלן מספר עבודות בולטות מהספרות המדעית שהיוו השראה מתודולוגית לפרויקט זה:

- **סיווג באמצעות למידת העברה (Apostolopoulos & Mpesiana, 2020):** במחקרם, בחנו החוקרים את היכולת לזהות קורונה מצילומי רנטגן על ידי שימוש בטכניקות של למידת העברה (Transfer Learning). הם השוו מספר ארכיטקטורות של מודלים שאומנו מראש (Pre-trained), ביניהן VGG19 ו-MobileNet. **תוצאות שהושגו:** העבודה הוכיחה כי שימוש במודלים שאומנו על מאגרים כלליים מאפשר להגיע לדיוק (Accuracy) של למעלה מ-96.7% בסיווג בינארי של קורונה, והדגישה כי למידת העברה היא כלי קריטי כאשר יש מחסור בסטים רפואיים גדולים ומתוייגים היטב.
- **שימוש בארכיטקטורות עמוקות (Chowdhury et al., 2020):** מחקר זה בדק האם מערכות בינה מלאכותית יכולות לשמש ככלי עזר לסיווג מהיר של דלקת ריאות ויראלית וקורונה. החוקרים השתמשו ברשתות מתקדמות כגון ResNet ו-DenseNet כדי לחלץ מאפיינים חזותיים מהצילומים. **תוצאות שהושגו:** המודלים השיגו דיוק גבוה של מעל 97% במספר קטגוריות. עם זאת, החוקרים ציינו כי האתגר המורכב ביותר הוא ההבדלה העדינה בין תמונות של קורונה לבין סוגים אחרים של דלקות ריאות ויראליות, אתגר שאיתו התמודדו גם בפרויקט שלנו.
- **מודל ייעודי לסיווג רב-מחלקתי (Ozturk et al., 2020):** החוקרים הציעו ארכיטקטורה מותאמת בשם DarkCovidNet שנועדה לזיהוי אוטומטי של מקרי קורונה. בניגוד למודלים רבים שהתמקדו בסיווג בינארי (חולה/בריא), מחקר זה התמקד גם בסיווג רב-מחלקתי

(Multi-class) הכולל אבחנה בין קורונה, דלקות ריאות ומצב ריאה תקין. **תוצאות שהושגו:** המודל הגיע לדיוק של כ-87.02% בסיווג רב-מחלקתי, תוצאה שממחישה את הקושי הטבעי שעולה ככל שמוסיפים יותר מחלקות רפואיות לבעיה.

עבודות אלו מהוות את הבסיס התיאורטי לבחירה שלנו בשימוש בארכיטקטורת ResNet50 ויישום של Transfer Learning. הן מוכיחות כי למודלים אלו יש את היכולת הנדרשת לחלץ מאפיינים רפואיים עדינים גם מבסיסי נתונים שאינם עצומים, ולהשיג ביצועים התומכים בקבלת החלטות קליניות.

3. שיטות (Methods)

א. גישת הלמידה העמוקה ותיאור המודל

בפרויקט זה בחרנו להשתמש בגישת **למידת העברה (Transfer Learning)** המבוססת על הארכיטקטורה המוכרת (Residual Networks) **ResNet50**. ארכיטקטורה זו, המכילה 50 שכבות עמוקות, פותרת את הבעיה הידועה של היעלמות הגרדיאנט (Vanishing Gradient) באמצעות חיבורי דילוג (Skip Connections). המודל אומן במקור על מאגר ImageNet הכולל מיליוני תמונות, ולכן הוא מחזיק ביכולת מוכחת וגבוהה לחלץ מאפיינים חזותיים מורכבים (כגון קצוות, טקסטורות וצורות). בגישה שלנו, השתמשנו בידע המוקדם של המודל כנקודת פתיחה לחילוף המאפיינים מצילומי הרנטגן הרפואיים שלנו, והתאמנו אותו ספציפית לזיהוי 4 מחלות הריאה.

ב. פירוט השיקולים בבחירת הרשת והפרמטרים

i. הארכיטקטורה והצדקת למידת העברה

הסיבה המרכזית לבחירה בגישת Transfer Learning היא מגבלת גודל הדאטה. למרות שברשותנו מעל ל-21,000 תמונות, אימון רשת עמוקה מאפס דורש לרוב מאות אלפי תמונות כדי למנוע התאמת יתר (Overfitting).

הארכיטקטורה שנבחרה כוללת את השכבות הבאות:

1. **Rescaling**: שכבת כניסה המנרמלת את ערכי הפיקסלים (חילוק ב-255).
2. **מודל הבסיס (ResNet50)**: שכבות הקונבולוציה המקוריות (ללא שכבות הסיווג המקוריות - `include_top=False`). כדי לאפשר למשקולות להתכוון במדויק לנתונים הרפואיים, "פתחנו" את השכבות (Unfreeze) לאימון מלא (Fine-tuning).
3. **Global Average Pooling 2D**: במקום שכבת Flatten שיוצרת עומס פרמטרים עצום, השתמשנו ב-GAP כדי לצמצם את המימד המרחבי ולייעל את החישוב.

4. **Dense 128 + ReLU**: שכבה מוסתרת ללמידת הקשרים לא-ליניאריים.
5. **(Dropout 0.2)**: איפוס אקראי של 20% מהנוירונים בכל אצווה למניעת תלות יתר ושינון של סט האימון.
6. **Dense 4**: שכבת הפלט המכילה 4 נוירונים, בהתאם ל-4 קטגוריות האבחון שלנו.

ii. פרוטוקול קצב הלמידה (Learning Rate)

השתמשנו בקצב למידה התחלתי של 0.001. קצב זה נבחר בקפידה (כפי שיפורט בסעיף ה-HPO) מכיוון שקצב גדול מדי היה "דורס" את המשקולות האיכותיות שהמודל הגיע איתן מאימון ה-ImageNet, ואילו קצב קטן מדי מנע מהמודל להתכנס.

iii. שיטת האופטימיזציה

בחרנו באופטימיזר **(Adam)** (Adaptive Moment Estimation). הבחירה נובעת מכך שהוא מתאים את קצב הלמידה בצורה אוטומטית ונפרדת לכל פרמטר ברשת, תוך התחשבות בהיסטוריית הגרדיאנטים (Momentum). זהו יתרון קריטי במודלים עמוקים ומרובי-פרמטרים כמו ResNet, המבטיח התכנסות מהירה ויציבה יותר לעומת SGD רגיל.

iv. פונקציית המחיר (Loss Function)

השתמשנו בפונקציית **Sparse Categorical Crossentropy** יחד עם הפרמטר `from_logits=True`.

ההצדקה: הבעיה שלנו היא סיווג רב-מחלקתי, והתגיות שלנו בסט הנתונים מקודדות כמספרים שלמים (0, 1, 2, 3) ולא כווקטורים של One-Hot Encoding. השימוש ב-logits מבטיח יציבות נומרית גבוהה יותר בחישוב השגיאה מאחורי הקלעים, לפני המרת הערכים להסתברויות בעזרת פונקציית Softmax.

v. כוונן היפר-פרמטרים (HPO)

תהליך מציאת הפרמטרים האופטימליים כלל מספר ניסויים והתאמות קריטיות:

- **קצב למידה ופתיחת מודל:** בניסויים הראשונים ביצענו הקפאה מלאה של ה-ResNet50 והשתמשנו בקצב למידה זעיר של $1e-5$. הדבר גרם לתת-למידה (Underfitting) קיצוני, שבו המודל חזה תמיד את המחלקה הנפוצה ביותר (Viral Pneumonia) והדיוק נתקע על 48%. כוונן קצב הלמידה לערך גבוה יותר ופתיחת משקולות המודל לאימון (Unfreezing) פתרו את הבעיה והזניקו את הדיוק הכללי לאזור ה-80%.

- **גודל אצווה וניהול זיכרון (Batch Size):** גודל האצווה נקבע ל-32. במהלך הניסויים נתקלנו בקריסות זיכרון (RAM Out of Memory) עקב שימוש בטכניקת Caching אגרסיבית על כל הדאטה. כווננו את ה-Pipeline כך שיעשה שימוש ב-tf.data.AUTOTUNE ובפונקציית prefetch בלבד, מה שאפשר עבודה יעילה ורציפה מול כרטיס ה-GPU T4 ללא קריסות.
- **משקלי מחלקות (Class Weights):** כדי לטפל בחוסר האיזון החריף בסט הנתונים (כ-10,000 תמונות Normal לעומת פחות מ-1,500 של Lung Opacity), חישבנו את יחסי התיקיות והזנו למודל מילון משקלים (class_weight). הדבר אילץ את המודל "לשלם מחיר" גבוה יותר על טעות במחלקות המיעוט וכך העלה משמעותית את ה-Recall שלהן.

ג. שחזור התוצאות

על מנת שקורא חיצוני יוכל לשחזר במדויק את התוצאות שהושגו (דיוק של כ-80%, ו-AUC של 0.99 במחלקת Lung Opacity), להלן הקינפוג (Configuration) המדויק להרצת האימון:

- **מידות קלט (Input Shape):** תמונות RGB בגודל 224x224x3.
- **מודל בסיס:** ResNet50 (משקולות ImageNet, ללא שכבת Top, פתוח לאימון trainable=True).
- **שכבות סיווג (Top Layer):** GAP2D -> Dense(128, ReLU) -> Dropout (0.2) -> Dense(4).
- **גודל אצווה (Batch Size):** 32.
- **אופטימיזר:** Adam.
- **תקופות אימון (Epochs):** 10.
- **אסטרטגיית אימון:** ללא שימוש ב-cache(), הזנת התמונות מתבצעת תוך שימוש ב-prefetch ושימוש במילון Class Weights מאוזן.

4. ניתוח ואנליזה

א+ב. ניתוח השיטות, השוואת מודלים ומדדי ביצועים במהלך הפרויקט בחנו שתי גישות עיקריות לאימון מודל ה-ResNet50, כאשר הראשונה נכשלה והשנייה (הסופית) הוכתרה כהצלחה:


1. **המודל שלא הצליח (הקפאה מלאה - Frozen Base):** בניסויים הראשונים, השתמשנו במודל ה-ResNet50 כאשר כל שכבות הקונבולוציה שלו מוקפאות, ורק שכבת הסיווג הסופית אומנה. מודל זה הגיע לדיוק נמוך מאוד של כ-48% וסבל מ"תת-למידה" (Underfitting). הוא פיתח נטייה לחזות כמעט תמיד את המחלקה הנפוצה ביותר (Viral)


(Pneumonia). **הסיבה לכישלון:** המשקולות המקוריות של ResNet50 אומנו על מאגר ImageNet (תמונות טבעיות של עצמים, בעלי חיים וכו'). מאפיינים אלו לא היו רגישים מספיק כדי לזהות את הטקסטורות העדינות והייחודיות של צילומי רנטגן רפואיים (כמו עכירות נוזלית או הצללות חלקיות).


2. המודל המוצלח (Fine-Tuning ומשקולות מחלקה): המודל הסופי, שאותו הצגנו בסעיף

הקודם, כלל פתיחה של כלל שכבות המודל לאימון (trainable=True) יחד עם הזנת משקלים (class_weights) שאיזנו את הנתונים. מודל זה עבד טוב יותר משמעותית והגיע לדיוק כללי (Accuracy) של 80% על סט הבדיקה (Validation Set). פתיחת השכבות אפשרה לפילטרים של הרשת להתכוון מחדש ולהתמחות ספציפית בפיצ'רים רפואיים של הריאות, בעוד שמילון המשקולות אילץ את המודל להתייחס ברצינות גם למחלקות המיעוט (כמו COVID ו-Lung Opacity).

```
Starting model training...
Epoch 1/10
1059/1059 ————— 468s 382ms/step - accuracy: 0.6540 - loss: 0.9547 - val_accuracy: 0.5862 - val_loss: 1.2903
Epoch 2/10
1059/1059 ————— 370s 349ms/step - accuracy: 0.7261 - loss: 0.7574 - val_accuracy: 0.6538 - val_loss: 0.8710
Epoch 3/10
1059/1059 ————— 369s 349ms/step - accuracy: 0.7434 - loss: 0.7138 - val_accuracy: 0.7712 - val_loss: 0.5808
Epoch 4/10
1059/1059 ————— 369s 349ms/step - accuracy: 0.7677 - loss: 0.6508 - val_accuracy: 0.7522 - val_loss: 0.6757
Epoch 5/10
1059/1059 ————— 369s 349ms/step - accuracy: 0.7776 - loss: 0.6181 - val_accuracy: 0.7573 - val_loss: 0.6223
Epoch 6/10
1059/1059 ————— 370s 349ms/step - accuracy: 0.7882 - loss: 0.5979 - val_accuracy: 0.7189 - val_loss: 0.6833
Epoch 7/10
1059/1059 ————— 370s 349ms/step - accuracy: 0.7950 - loss: 0.5722 - val_accuracy: 0.7543 - val_loss: 0.6705
Epoch 8/10
1059/1059 ————— 382s 349ms/step - accuracy: 0.8079 - loss: 0.5406 - val_accuracy: 0.7048 - val_loss: 0.9554
Epoch 9/10
1059/1059 ————— 369s 349ms/step - accuracy: 0.8176 - loss: 0.5090 - val_accuracy: 0.7815 - val_loss: 0.5527
Epoch 10/10
1059/1059 ————— 369s 349ms/step - accuracy: 0.8254 - loss: 0.4885 - val_accuracy: 0.8019 - val_loss: 0.5484
Training completed!
```







ג. ויזואליזציות והערכת ביצועים כדי להעריך את איכות המודל, הפקנו מספר ויזואליזציות ומדדים סטטיסטיים (המוצגים בגרפים בדו"ח):

● **מטריצת בלבול (Confusion Matrix) ודוח סיווג:** מטריצת הבלבול חושפת את החוזקות והחולשות של המודל בסיווג 4 המחלקות.

- **דלקת ריאות ויראלית (Viral Pneumonia):** המודל הפגין ביצועים מצוינים במחלקה זו עם Recall של 0.91 ו-F1-Score של 0.86. מתוך 4,048 תמונות, הוא זיהה נכון 3,688 מקרים.
- **עכירות בריאה (Lung Opacity):** למרות שזו קבוצת המיעוט הקטנה ביותר (499 תמונות בסט הבדיקה), המודל השיג Precision מעולה של 0.96. כלומר, כשהמודל קובע שיש עכירות, הוא כמעט ולא טועה (False Positives נמוכים מאוד).
- **COVID ו-Normal (בריא):** כאן המודל התקשה מעט יותר (F1-score של 0.67 ו-0.76 בהתאמה). ניתן לראות במטריצה שישנו בלבול מסוים בין חולי קורונה

לאנשים בריאים (282 תמונות קורונה סווגו כדלקת ריאות רגילה, ו-173 סווגו כבריאות). דבר זה הגיוני קלינית, שכן בשלביה הראשונים של מחלת הקורונה, צילום החזה עשוי להראות תקין או דומה מאוד לדלקת ויראלית סטנדרטית.

- **עקומת ROC (Receiver Operating Characteristic):** הפקנו עקומות ROC לכל מחלקה בשיטת One-vs-Rest. התוצאות מדגימות יכולת הפרדה קלינית טובה מאוד של הרשת:

- Lung Opacity קיבל ציון כמעט מושלם של $AUC = 0.99$.
- Viral Pneumonia עם $AUC = 0.91$.
- COVID עם $AUC = 0.85$.
- Normal עם $AUC = 0.73$.

ד. דיון בעקומות הלימוד וראיות מהניסוי ניתוח עקומות הלמידה של המודל הסופי (Training vs. Validation) מספק ראיות נוספות ליציבותו:

- **עקומת הדיוק (Accuracy):** ניתן לראות טיפוס עקבי של הדיוק לאורך 10 ה-Epochs, הן על סט האימון והן על סט הולידציה. העובדה שדיוק הולידציה נשאר קרוב לדיוק האימון (ואף עוקף אותו בחלק מהזמן, כנראה בזכות שימוש ב-Dropout שפעיל רק באימון) מעידה על כך שהמודל מבצע הכללה טובה ולא סובל מ-Overfitting חמור.
- **עקומת השגיאה (Loss):** השגיאה על סט האימון יורדת בצורה חלקה ומונטונית. גם עקומת שגיאת הולידציה יורדת באופן כללי, למרות תנודתיות קלה (Spikes) באזורי Epoch 3 ו-7, אשר אופיינית לשימוש בקצב למידה קבוע ($1e-3$) עם אופטימיזר Adam בסביבה פתוחה ל-Fine-tuning.

לסיכום, בחירת המודל ותהליך ה-HPO שביצענו (כוון משקלים, שחרור שכבות, וניהול הזיכרון בעזרת prefetch) הוכיחו את עצמם כפתרון היעיל ביותר עבורנו במסגרת מגבלות החומרה והזמן. למרות שהמודל לא מגיע ל-100% דיוק ומתקשה בהבחנות דקות בין קורונה לריאה תקינה, הוא מספק תוצאות מרשימות שמאפשרות סינון ראשוני מהיר ויעיל בסטנדרטים של למידה עמוקה.

5. דיון ומסקנות

מסקנות עיקריות מתוצאות הפרויקט מהעבודה והתוצאות שהשגנו, ניתן להסיק כי שימוש בלמידת העברה (Transfer Learning) מבוסס ResNet50 מהווה כלי עוצמתי ויעיל לסיווג תמונות רפואיות, גם תחת מגבלות של חוסר איזון טבעי בנתונים ומשאבי חישוב. המודל הפגין ביצועים מרשימים (AUC של 0.99 ו-0.91) בזיהוי פתולוגיות מובהקות כגון עכירות בריאה ודלקת ריאות ויראלית.

עם זאת, התגלה קושי מובנה בהבחנה בין צילומי חזה של חולי קורונה (COVID-19) לבין צילומים של ריאות תקינות (Normal). מסקנתנו היא שהאתגר אינו נובע רק ממגבלות המודל, אלא מהאופי הקליני של מחלת הקורונה, אשר בשלביה המוקדמים לא תמיד משאירה חותם ויזואלי ברור בצילום הרנטגן. לכן, המערכת כפי שהיא כיום מתאימה לשמש ככלי עזר טכנולוגי לסינון ראשוני ולתעדוף מקרים דחופים (Triage) עבור הרדיולוג או הרופא המטפל, אך אינה בשלה להחלפת שיקול הדעת הרפואי האנושי באופן אוטונומי.

גישות חלופיות בהינתן משאבי זמן נוספים לו היה עומד לרשותנו זמן רב יותר לפיתוח, היינו בוחנים את הגישות הבאות במטרה לשפר את אחוזי הדיוק של המודל:

1. **אוגמנטציית נתונים מתקדמת (Data Augmentation):** הוספת שכבות של העשרת נתונים בזמן אמת ב-Pipeline (כגון סיבובים קלים, שינויי בהירות, ותקריבים - Zoom). פעולה זו הייתה מייצרת תמונות "סינתטיות" חדשות, מגדילה את מאגר המידע, ועוזרת למודל להתמודד טוב יותר עם צילומים באיכויות או בזוויות צילום שונות וכך למנוע התאמת יתר (Overfitting).
2. **למידת אנמבל (Ensemble Learning):** במקום להסתמך אך ורק על מודל ResNet50, היינו מאמנים במקביל רשתות ארכיטקטורה מתקדמות נוספות (כגון DenseNet121 או EfficientNet) ומשלבים את התחזיות שלהן יחד באמצעות שקלול. גישה זו לרוב מקטינה את שגיאת ההכללה ומעלה את האמינות של הסיווג הסופי.
3. **חיפוש היפר-פרמטרים אוטומטי (Hyperparameter Optimization):** מעבר מכוון ידני לשימוש בספריות ייעודיות כמו Keras Tuner (הטמעת שיטות Grid Search או Random Search) כדי למצוא בצורה מתמטית ומקיפה את קצב הלמידה, כמות הנירונים בשכבות ה-Dense ואחוזי ה-Dropout האופטימליים ביותר למערכת.

עבודה נוספת הנדרשת להשלמת הפרויקט ברמה המעשית כדי להפוך את המודל מאב-טיפוס מחקרי למוצר שניתן להטמיע בפועל בבתי חולים, נדרשת עבודה נוספת בשני מישורים עיקריים:

- **הסברתיות רפואית (Explainable AI - XAI):** בסביבה רפואית, רופא אינו יכול לקבל החלטות על סמך "קופסה שחורה". עבודה עתידית תכלול יישום טכניקות כמו **Grad-CAM**, אשר ייצרו "מפות חום" (Heatmaps) על גבי צילומי הרנטגן, וכך יסמנו לרופא ויזואלית אילו אזורים ספציפיים בריאה גרמו לרשת להחליט שמדובר בתחלואה.
- **אינטגרציה למערכות בית החולים:** המודל הנוכחי שלנו מותאם לקבל תמונות בפורמטים סטנדרטיים וקלים לחישוב (PNG/JPG). נדרשת התאמה טכנית נרחבת של הקוד כך שידע לקרוא, לפענח ולעבד קבצי **DICOM** (הפורמט הרפואי הסטנדרטי של צילומי רנטגן)

במערכות ה-PACS), הכוללים רזולוציות גבוהות בהרבה ומטא-דאטה קליני מוצפן הנדרש להמשך טיפול.

6. הפניות וביבליוגרפיה

[Apostolopoulos, I. D., & Mpesiana, T. A. \(2020\).](#) Covid-19: automatic detection from X-ray images utilizing transfer learning with convolutional neural networks. *Physical and Engineering Sciences in Medicine*, 43(2), 635-640.

[Chowdhury, M. E., Rahman, T., Khandakar, A., Mazhar, R., Kadir, M. A., Mahbub, Z. B., ... & Reaz, M. B. I. \(2020\).](#) Can AI help in screening viral and COVID-19 pneumonia? *IEEE Access*, 8, 132665-132676.

[He, K., Zhang, X., Ren, S., & Sun, J. \(2016\).](#) Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).

[Ozturk, T., Talo, M., Yildirim, E. A., Baloglu, U. B., Yildirim, O., & Acharya, U. R. \(2020\).](#) Automated detection of COVID-19 cases using deep neural networks with X-ray images. *Computers in Biology and Medicine*, 121, 103792.

[Rahman, T. \(2021\).](#) COVID-19 Radiography Database. Kaggle. Retrieved from <https://www.kaggle.com/tawsifurrahman/covid19-radiography-database>

7. תרומה מפורטת של כל סטודנט בפרויקט

רוחן מיליכוב:

- **מחקר וארכיטקטורה:** סקירת הספרות האקדמית הקשורה, קבלת ההחלטה על שימוש בגישת למידת העברה, והגדרת ארכיטקטורת המודל המבוססת על ResNet50 כולל שכבות הסיווג החדשות.
- **עיבוד נתונים:** כתיבת הקוד לטעינת הנתונים, שינוי מידות התמונות, ונרמול הפיקסלים. פיתוח המנגנון לחישוב אוטומטי של משקלי המחלקות (class_weights) לצורך טיפול בחוסר האיזון המובנה במאגר הנתונים.
- **תיעוד:** ניסוח פרקי המבוא, עבודה קשורה (Related Work) והשיטות בדו"ח המסכם.

שחר וילק:

- **אימון ואופטימיזציה (HPO):** ניהול תהליך האימון של המודל, בחירת האופטימיזר (Adam) וקצב הלמידה, וכיוון שחרור השכבות (Unfreezing). פתרון בעיות משאבי הזיכרון בעזרת שילוב מנגנון ה-prefetch להזרמת נתונים חלקה למאיץ הגרפי.
- **הערכת ביצועים (Evaluation):** כתיבת הקוד להפקת המדדים הסטטיסטיים, יצירת מטריצת הבלבול (Confusion Matrix), ובניית עקומות ה-ROC וה-AUC לכלל המחלקות.
- **תוצרים ויזואליים וניתוח:** הכנת מצגת הפרויקט המסכמת, וניסוח פרקי הניתוח והדיון (Discussion) בדו"ח.

8. נספח – מבנה הקוד, קבצים והוראות הרצה

א. תיאור קבצי הקוד

הקוד המרכזי של הפרויקט מאוגד כולו במחברת אחת (ipynb) ובקובץ הסקריפט התואם לה (py). הקוד כתוב בצורה מודולרית ומחולק לתאים (Cells) בעלי תפקידים מוגדרים:

1. **ייבוא ספריות והורדת נתונים:** שימוש בספריית kagglehub כדי למשוך את ה-Dataset העדכני ישירות משרתי Kaggle לתוך סביבת הריצה, ללא צורך בהורדה ידנית.
2. **עיבוד מקדים והגדרת ארכיטקטורה:** הגדרת ה-Pipeline להזרמת נתונים (כולל שינוי גודל ל-224x224 ונרמול), טעינת מודל ה-ResNet50 ללא שכבות הסיווג המקוריות (Transfer Learning), ובניית ראש הסיווג החדש.
3. **אימון והערכה:** חישוב דינמי של משקלי המחלקות לאיזון הנתונים, הרצת האימון (fit) בעזרת מתזמן prefetch לניהול זיכרון ה-RAM, והפקת גרפים (ROC, מטריצת בלבול, פונקציית מחיר ודיוק).

ב. הוראות הרצה מפורטות

על מנת לשחזר את התוצאות המוצגות בדו"ח זה, יש לבצע את השלבים הבאים:

1. **סביבת עבודה:** מומלץ לפתוח את המחברת `medical_images_processing_final_project.ipynb` בסביבת **Google Colab**.
2. **הקצאת חומרה (קריטי):** מכיוון שמדובר באימון של רשת עמוקה (כ-23 מיליון פרמטרים), הרצה על CPU רגיל תיקח זמן רב מדי. יש לגשת בתפריט העליון ל-`Runtime -> Change runtime type`, ולבחור במאיץ חומרתי מסוג **T4 GPU** (או מקביל לו).
3. **הרצת הקוד:** יש להריץ את כל תאי המחברת לפי הסדר (`Runtime -> Run all`).
4. **תהליך אוטומטי:** אין צורך להוריד או למקם קבצים באופן ידני. הקוד יוריד את מאגר התמונות, יחלץ אותו, יאמן את המודל במשך 10 Epochs, יציג את כל הויזואליזציות,

ולבסוף ישמור את המודל המאומן כקובץ בשם `medical_chest_classifier.keras` בתיקיית העבודה הנוכחית.

ג. עץ הפרויקט (רשימת הקבצים)

- **`medical_images_processing_final_project.ipynb`**: מחברת הקוד הראשית (מותאמת לסביבת Google Colab). קוד זה כתוב בצורה מודולרית וכולל את כל שלבי ייבוא הנתונים, העיבוד המקדים, בניית ארכיטקטורת ה-ResNet50, האימון והפקת הגרפים להערכת הביצועים.
- **`Medical_Imaging_Presentation.pdf`**: מצגת הפרויקט המציגה את הבעיה הרפואית, את הנתונים ואת הפתרון שלנו באופן ויזואלי ותמציתי.
- **`Medical Images Processing Final Project - Summary Report.pdf`**: הדו"ח המסכם (מסמך זה) המפרט לעומק את שיטות הלמידה העמוקה ואת ניתוח התוצאות הסטטיסטיות.
- **`README.md`**: קובץ הסבר קצר באנגלית המשמש כעמוד השער לפרויקט (עבור מאגר ה-GitHub) ומספק סקירה מהירה והוראות הרצה.
- **`medical_chest_classifier.keras`**: קובץ המודל המאומן. קובץ זה נוצר ונשמר אוטומטית בתיקיית פלט (output) פנימית בסיום תהליך הרצת המחברת.