

סיווג מחלות בריאות

עיבוד תמונות רפואיות ולמידה עמוקה - הצגת הפרויקט

מגישים: רונן מיליכוב ושחר וילק



האתגר הרפואי וחשיבות הפרויקט

למה בחרנו דווקא בבעיה הזו?

- העומס על מערכת הבריאות – רדיולוגים ורופאים קורסים תחת עומס מטורף של אבחון צילומים, במיוחד בתקופות של מגפות
- גורם הזמן – אבחון איטי של דלקת ריאות או קורונה יכול להוביל להחמרה רפואית קשה של החולה

הפתרון שלנו

כלי עזר מבוסס AI שיבצע סינון ראשוני מהיר, יקפוץ על מקרים דחופים ויקל על הרופאים

הגדרת הבעיה - הקלט והפלט

איך הגדרנו את בעיית הסיווג?

- **הקלט (Input)** - תמונות רנטגן דו-מימדיות דיגיטליות של בית החזה
- **הפלט (Output)** - סיווג אוטומטי לאחת מארבע קטגוריות רפואיות שונות:
 - 1. קורונה
 - 2. דלקת ריאות ויראלית
 - 3. עכירות בריאה
 - 4. ריאה בריאה


מאגר התמונות שלנו

הדאטה של הפרויקט

המקור: מאגר רפואי פתוח באתר Kaggle (COVID-19 Radiography Database)
כמות הדוגמאות: למעלה מ-21,000 צילומי רנטגן מתוירים. כמות גדולה ומספקת של תמונות.

חלוקת הנתונים שלנו:

- 80% – ט אימון (Training): השלב שבו המודל ילמד ויכונן את המשקולות שלו
- 20% – ט בדיקה (Validation): תמונות שהמודל לא יראה אף פעם, לבדיקה 'על עיוור'



עיבוד מקדים ונרמול הנתונים

הכנת התמונות לאימון

- שינוי גודל (Resizing): כיווץ ואחידות של כל התמונות לגודל של 224 על 224 פיקסלים (הסטנדרט של רשתות CNN כדי שיוכלו לעבוד ביעילות)
- נרמול הפיקסלים (Normalization): חלוקת ערכי הפיקסלים ב-255 כדי להעביר אותם מטווח של [0-255] לטווח שברים עדין של [0-1]

למה אנחנו עושים את זה?

- מונע קריסה מתמטית של המחשב בזמן הכפל מיליוני פעמים (Exploding Gradients)
- מאפשר למודל לעשות 'צעדי למידה' עדינים ויציבים יותר ולרוץ מהר

דוגמאות רפואיות



אז איך הדאטה שלנו נראה באמת?

Normal: ריאה נקייה לגמרי, רואים שהאוויר זורם חופשי (הכתמים השחורים הגדולים)

Viral Pneumonia: יש "לכלוך" מפוזר ונוזלים בריאות שמפריעים לצילום לעבור

COVID-19: סימן היכר ברור - הצללות שנראות כמו "זכוכית מט" ממש בקצוות של הריאה

Lung Opacity: אזורים עכורים ורחבים, לא משהו שאפשר להצביע עליו כדלקת ספציפית



המטא-דאטה והשימוש בו

ניתוח ה-Metadata של המאגר

מה קיבלנו במאגר? קבצי Excel נפרדים המכילים מידע על המקור הקליני של התמונות (למשל, שיוך למאגרים עולמיים כמו BIMCV מספרד או מאגר Cohen)

החלטת הפרויקט שלנו:

- החלטנו **להתעלם** מהנתונים הטבלאיים האלו (כמו שם בית החולים או המחקר)
- המודל שלנו יתבסס **אך ורק על המידע החזותי** (התמונות עצמן)

ההצדקה: לשמור על אופי הפרויקט כפרויקט טהור של עיבוד תמונה רפואית וראייה ממוחשבת

גישת הפתרון – רשת ה-CNN שבנינו

Model: "sequential"

Layer (type)	Output Shape	Param #
rescaling (Rescaling)	(None, 224, 224, 3)	0
conv2d (Conv2D)	(None, 224, 224, 16)	448
max_pooling2d (MaxPooling2D)	(None, 112, 112, 16)	0
conv2d_1 (Conv2D)	(None, 112, 112, 32)	4,640
max_pooling2d_1 (MaxPooling2D)	(None, 56, 56, 32)	0
flatten (Flatten)	(None, 100352)	0
dense (Dense)	(None, 128)	12,845,184
dense_1 (Dense)	(None, 4)	516

Total params: 12,850,788 (49.02 MB)
Trainable params: 12,850,788 (49.02 MB)
Non-trainable params: 0 (0.00 B)

ארכיטקטורת המודל

מבנה הרשת:

מודל רציף (Sequential) המורכב מ-2 בלוקים מרכזיים:

- **חילוך מאפיינים:** שכבות קונבולוציה (Conv2D) המשמשות כ'זכוכית מגדלת' למציאת כתמים והצללות, ושכבות כיווץ (MaxPooling2D) לחסכון בזיכרון.
- **קבלת החלטה:** שכבת השטחה (Flatten) שהופכת את המטריצה לשורה ארוכה, ושכבות צפופות (Dense) לקטלוג הסופי.

תוכנית העבודה לסיום הפרויקט

העבודה שנותרה לנו

- **אסטרטגיית אימון (Training):** הרצת האימון בפועל בעזרת פונקציית הפסד SparseCategoricalCrossentropy (לחישוב גודל הטעות) ואופטימיזר Adam (לתיקון המשקולות)
- **כוונון המערכת (HPO):** ניסוי וטעייה של היפר-פרמטרים: קצב למידה (Learning Rate) וגודל קבוצה (Batch Size) כדי למקסם תוצאות
- **אוגמנטציה:** סיבוב והפיכת תמונות בזמן אמת כדי למנוע מהרשת לשנן את התמונות בעל פה (Overfitting)
- **מדדי הצלחה רפואיים:** הפקת אחוזי דיוק, מטריצת בלבול (Confusion Matrix) לזיהוי טעויות נפוצות, ועקומות ביצועים (ROC)